

سامانه‌ی جست‌وجوی دو موتور و تولید مبتنی بر بازیابی

مستند پیاده‌سازی پروژه‌ی پایانی درس بازیابی اطلاعات نوین

Dual-Engine Document Search & RAG System

دانشگاه صنعتی شریف — پردیس بین‌الملل

درس: بازیابی اطلاعات نوین

مدرس: امیرعلی قهرمانی

این مستند توضیح می‌دهد که هر بخش سامانه چگونه پیاده‌سازی شده،


با چه فرمولی محاسبه می‌شود، و به کدام اسلاید درس برمی‌گردد.

فهرست مطالب

۱. معماری کلی و جریان داده
۲. خط لوله‌ی نمایه‌سازی: پارس، قطعه‌بندی، دو نمایه
۳. پیش‌پردازش متن: از واژه تا ترم
۴. نمایه‌ی معکوس و ساختارهای داده
۵. مدل فضای برداری (VSM) با وزن‌دهی Inc.ltc
۶. انتخاب K سند برتر با هیپ کمینه
۷. بازیابی نادقیق K برتر: فهرست قهرمانان و حذف نمایه
۸. مدل احتمالاتی Okapi BM25
۹. بازخورد شبه‌ربط با الگوریتم Rocchio
۱۰. موتور معنایی و فرایند RAG
۱۱. همگام‌سازی دو نمایه
۱۲. جدول کامل پارامترها
۱۳. نگاشت پیاده‌سازی به اسلایدهای درس

۱. معماری کلی و جریان داده

سامانه دو انبار داده‌ی موازی نگه می‌دارد که هر دو از یک منبع حقیقت واحد (پایگاه‌داده‌ی SQLite) مشتق می‌شوند: یک نمایه‌ی معکوس که از صفر نوشته شده و موتورهای واژگانی روی آن کار می‌کنند، و یک پایگاه‌داده‌ی برداری (ChromaDB) که بازیابی معنایی و RAG روی آن انجام می‌شود.



هر سه موتور یک امضای یکسان دارند — `(query, k, mode, prf) → {"hits", "scored"}` — و در `engines/registry.py` در یک دیکشنری ساده ثبت شده‌اند. مقدار `scored` اندازه‌ی مجموعه‌ی نامزدهاست که واقعاً امتیازدهی شده، و همان عددی است که صرفه‌جویی روش‌های نادقیق را قابل اندازه‌گیری می‌کند.

واحد بازیابی: سند، نه قطعه

یک تصمیم‌بنیادی که در سرتاسر کد رعایت شده این است که **واحد امتیازدهی، سند است نه قطعه**. قطعه‌بندی یک ضرورت فنی پنجره‌ی متنی مدل تعبیه‌سازی است، نه چیزی که کاربر دنبالش می‌گردد. این تصمیم سه پیامد ریاضی مستقیم دارد:

- `df` یعنی «سامد سندی»؛ اگر روی قطعه‌ها شمرده شود، دیگر `idf` نیست و نادر بودن یک ترم به شیوه‌ی تصادفی تکه‌تکه‌شدن متن وابسته می‌شود.
- پارامتر `b` در `BM25` برای مهار سندهای بلند وجود دارد؛ اما قطعه‌بندی به‌طور ساختاری طول همه‌ی قطعه‌ها را تقریباً یکسان می‌کند، پس نرمال‌سازی روی طول قطعه، واریانسی را تصحیح می‌کند که خودِ قطعه‌بندی از بین برده است.
- یک سند بلند نباید بتواند با تقسیم‌شدن به چند قطعه‌ی کوتاه از جریمه‌ی طول فرار کند و چند جای فهرست نتایج را اشغال کند.

بنابراین نمایه در یک گذر، دو سطح می‌سازد: سطح قطعه (برای `RAG` و برای انتخاب متن نمونه) و سطح سند (برای امتیازدهی `VSM` و `BM25` و `Rocchio`).

۲. خط لوله‌ی نمایه‌سازی

۲.۱ پارس فایل

فایل‌های `.pdf` با کتابخانه‌ی `PyMuPDF` و فایل‌های `.docx` با `python-docx` خوانده می‌شوند (`services/ingest.py`). خروجی هر پارسر یک زوج `(text, title)` است؛ اگر فایل عنوان فرادادای نداشته باشد، نام فایلی که کاربر انتخاب کرده مبنا قرار می‌گیرد — نه مسیر فایل موقت، چون در غیر این صورت سند با نامی مثل `tmpoqta_cli` در فهرست ظاهر می‌شود.

۲.۲ قطعه‌بندی

از `RecursiveCharacterTextSplitter` استفاده شده که مرزهای پاراگراف و جمله را محترم می‌شمارد. نکته‌ی ظریف پیاده‌سازی این است که مشخصات پروژه اندازه‌ی قطعه را برحسب کلمه تعریف کرده، در حالی که این کلاس به‌طور پیش‌فرض کاراکتر می‌شمارد؛ بنابراین تابع طول جایگزین شده است:

```
_splitter = RecursiveCharacterTextSplitter(  
    chunk_size=500, chunk_overlap=50,  
    length_function=lambda t: len(t.split()), # words, not characters  
)
```

همپوشانی ۵۰ کلمه‌ای تضمین می‌کند جمله‌ای که دقیقاً روی مرز دو قطعه می‌افتد، در هیچ‌کدام نصفه نماند.

۲.۳ نمایه‌سازی دوگانه

هر قطعه هم‌زمان به دو انبار می‌رود: توکن‌ها و بسامدشان به نمایه‌ی معکوس، و متن خام پس از تعبیه‌سازی به Chroma. شناسه‌ی قطعه در هر دو یکسان است ({doc_id}:{ordinal}) و همین است که حذف همگام را به یک جست‌وجوی کلیدی تبدیل می‌کند، نه پویش کل انبار.

۳. پیش‌پردازش متن: از واژه تا ترم

اسلاید ۵ فصل سوم تفاوت «واژه» و «ترم» را تعریف می‌کند: واژه رشته‌ای است که در متن دیده می‌شود، و ترم یک کلاس هم‌ارزی نرمال‌شده است. کل ماژول `engines/lexical/text.py` برای همین تبدیل نوشته شده، و مراحل دقیقاً به همان ترتیبی‌اند که اسلایدها معرفی می‌کنند:

مرحله	پیاده‌سازی	نمونه و دلیل
حذف نقطه در سرواژه‌ها s11	<code>_ACRONYM_RE</code>	U.S.A. → USA — الگو محدود به دنباله‌ی «حرف+نقطه» است تا قاعده‌ی عمومی «هر نقطه را حذف کن» مرزهای جمله‌ای را که استخراج PDF بدون فاصله می‌گذارد به هم نچسباند.
حذف خط تیره s11	<code>_HYPHEN_RE</code>	anti-discriminatory → antidiscriminatory — فقط بین دو نویسه‌ی واژه‌ای.
حذف اعراب و تشدید s22	NFKD + combining	résumé → resume؛ همین گام حرکات عربی و لیگاتورهای PDF (file → file) را هم یکدست می‌کند.
یکسان‌سازی حروف بزرگ و کوچک s14	<code>.lower()</code>	معیار اسلاید: «کاربر احتمالاً چطور پرس‌وجو را می‌نویسد؟»
توکن‌سازی s6	<code>[^\W_]+</code>	الگوی قدیمی‌تر <code>[a-z0-9]+</code> برای فارسی و عربی و سیریلیک صفر توکن تولید می‌کرد؛ این الگو یونیکد-آگاه است.
ریشه‌یابی s17-18	snowball "porter"	organize / organizes / organizing → organ. اسلاید تصریح می‌کند شکل دقیق ریشه اهمیت‌ی ندارد، فقط کلاس هم‌ارزی مهم است.

چرا فهرست ایست‌واژه نداریم؟ اسلاید ۱۰ می‌گوید روند عمومی به سمت حذف‌نکردن ایست‌واژه‌هاست، و از آن مهم‌تر: پیکره‌ی این سامانه **متغیر** است — کاربر هر لحظه سند اضافه یا حذف می‌کند، پس هر فهرستی که از بسامد پیکره ساخته شود بلافاصله کهنه می‌شود. به‌جای آن، ترم‌های پُربسامد در زمان پرس‌وجو با «حذف نمایه» بر پایه‌ی idf کنار گذاشته می‌شوند (بخش ۷)، که هیچ فهرست ذخیره‌شده‌ای لازم ندارد و خودش را با پیکره تطبیق می‌دهد.

یک مسیر، نه دو مسیر. اسلاید ۱۱ تأکید می‌کند: «حیاتی است که متن نمایه‌شده و ترم‌های پرس‌وجو به یک شکل نرمال شوند.» به همین دلیل `tokenize()` تنها در ورودی است: نوشتن در نمایه، VSM، BM25، Rocchio و حتی برجسته‌سازی ترم‌ها در متن نمونه همگی همین یک تابع را صدا می‌زنند، پس امکان ندارد دو طرف به دو کلاس هم‌ارزی متفاوت برسند.

۲. نمایه‌ی معکوس و ساختارهای داده

کلاس `InvertedIndex` این نگاشت‌ها را نگه می‌دارد:

نقش	نگاشت	structure
نمایه‌ی معکوس اصلی، در سطح قطعه	$\text{term} \rightarrow \{\text{chunk_id: tf}\}$	postings
حذف در زمان $O(\text{terms})$	$\text{chunk_id} \rightarrow \{\text{term: tf}\}$	forward
انتخاب قطعه‌ی متن نمونه	$\text{chunk_id} \rightarrow \text{float}$	chunk_norm
بسامد ترم در کل سند (جمع قطعه‌ها)	$\text{doc_id} \rightarrow \{\text{term: tf}\}$	doc_forward
محاسبه‌ی df	$\text{term} \rightarrow \{\text{doc_id}\}$	doc_postings
BM25 در dl	$\text{doc_id} \rightarrow \text{int}$	doc_len
مؤلفه‌ی c در lnc	$\text{doc_id} \rightarrow \text{float}$	doc_norm

۴.۱ بسامد سندی و idf

$$df_t = |\{d : t \in d\}| \quad idf_t = \log_{10} \frac{N}{df_t}$$

N تعداد کل اسناد است؛ برای ترم دیده‌نشده و برای ترمی که در همه‌ی اسناد هست، idf برابر صفر می‌شود

این‌که idf برای ترم موجود در همه‌ی اسناد دقیقاً صفر می‌شود، صرفاً یک جزئیات ریاضی نیست: همان چیزی است که باعث می‌شود چنین ترمی در هیچ امتیازی سهم نداشته باشد، و در نتیجه در کد چند جا با شرط $idf(t) > 0$ کلاً از مجموعه‌ی نامزدها کنار گذاشته می‌شود.

۴.۲ نمایه‌ی رو به جلو و هزینه‌ی آن

نگه‌داشتن forward حافظه را دو برابر می‌کند، و در عوض حذف را دقیق و ارزان می‌سازد: حذف یک سند فقط ترم‌هایی را لمس می‌کند که واقعاً در آن سند بودند، به‌جای پویش کل واژگان. در مقیاس این پروژه معامله‌ی درستی است.

۴.۳ نسخه‌بندی نمایه

نمایه به‌صورت pickle ذخیره می‌شود، اما همراه با دو برجسب:

```
ANALYZER = "s11-periods+hyphens/s22-deaccent/s14-fold/s17-porter"
SCHEMA   = 2
```

اگر روش تبدیل واژه به ترم عوض شود، ANALYZER تغییر می‌کند و نمایه بازسازی اجباری می‌شود. بررسی مبتنی بر «تعداد قطعه‌ها» اینجا کار نمی‌کند: تغییر تحلیل‌گر تعداد را دست‌نخورده می‌گذارد و فقط **ترم‌ها** جابه‌جا می‌شوند، پس نمایه بی‌سروصدا به پرس‌وجویی که یک‌جور توکن‌سازی شده با پستینگ‌هایی که جور دیگری ساخته شده‌اند پاسخ می‌داد.

۵. مدل فضای برداری با وزن‌دهی lnc.ltc

اسلاید ۴۱ فصل «امتیازدهی» نمادگذاری SMART را به شکل ddd.qqq معرفی می‌کند و lnc.ltc را «یک طرح وزن‌دهی بسیار استاندارد» می‌نامد. این سامانه دقیقاً همین را پیاده کرده است:

سمت	کد	معنا
سند	lnc	logarithmic tf, بدون idf (no), نرمال‌سازی cosine
پرس‌وجو	ltc	logarithmic tf, با tf-idf, نرمال‌سازی cosine

۵.۱ وزن لگاریتمی بسامد

$$w_{tf}(tf) = \{ \quad 1 + \log_{10}(tf) \quad tf > 0 \quad ; \quad 0 \quad tf = 0 \}$$

اسلاید s17 — ده بار تکرار یک ترم، سند را ده برابر مرتبط‌تر نمی‌کند

۵.۲ بردار پرس‌وجو (ltc)

$$w_{t,q} = (1 + \log_{10} tf_{t,q}) \cdot idf_t \quad \hat{q}_t = \frac{w_{t,q}}{\sqrt{(\sum_{t' \in q} w_{t',q}^2)}}$$

۵.۳ بردار سند (lnc)

$$w_{t,d} = 1 + \log_{10} tf_{t,d} \quad ||d|| = \sqrt{(\sum_{t \in d} w_{t,d}^2)}$$

$tf_{t,d}$ جمع بسامد ترم روی همه‌ی قطعه‌های آن سند است، و $||d||$ روی کل سند محاسبه می‌شود

چرا سمت سند idf ندارد؟ همان حرف n در lnc است و عمدی است. مقدار idf نادر بودن یک ترم در کل پیکره را توصیف می‌کند — خاصیتی از ترم، نه از یک سند خاص. اگر در هر دو سمت اعمال شود، عملاً idf به توان دو می‌رسد و اثرش دو برابر می‌شود.

$$\text{score}(q, d) = \sum_{t \in q \cap d} \hat{q}_t \cdot \frac{1 + \log_{10} \text{tf}_{t,d}}{||d||}$$

چون هر دو بردار واحدند، این حاصل ضرب داخلی دقیقاً همان شباهت کسینوسی است

نکته‌ی کارایی: جمع فقط روی ترم‌های پرس‌وجو زده می‌شود و فقط پستینگ‌های همان ترم‌ها پیمایش می‌شوند. پس هزینه متناسب با طول پستینگ‌های پرس‌وجو است، نه با اندازه‌ی پیکره `s5 8-Scoring`.

۵.۵ انتخاب متن نمونه

واحد رتبه‌بندی سند است، اما رابط کاربری به یک قطعه‌ی متن نیاز دارد. تابع `best_chunk` برای هر سند برنده، قطعه‌ای را برمی‌گرداند که بیشترین امتیاز `ltc` را نسبت به پرس‌وجو دارد — یعنی همان پاراگرافی که سند را به این رتبه رسانده، نه صرفاً اولین پاراگراف آن.

$$\text{best}(d, q) = \arg \max_{c \in \text{chunks}(d)} \sum_{t \in q \cap c} (1 + \log_{10} \text{tf}_{t,c}) \cdot \text{idf}_t$$

۶. انتخاب K سند برتر با هیپ کمینه

اسلایدهای ۱۳ و ۱۴ فصل «امتیازدهی در سامانه‌ی جست‌وجو» می‌گویند برای یافتن K سند برتر نیازی به مرتب‌سازی هر N امتیاز نیست. کلاس `TopKMinHeap` یک هیپ دودویی کمینه با ظرفیت ثابت است:

```
if len(heap) < k:           heap.append(...); sift_up(...)      # O(log k)
elif score > heap[0][0]:    heap[0] = (...); sift_down(0)      # O(log k)
else:                      reject                             # O(1)
```

$$O(N \log K) \quad \text{در برابر} \quad O(N \log N)$$

ریشه‌ی هیپ همیشه ضعیف‌ترین K مورد نگه‌داشته‌شده است، پس رد کردن یک نامزد در زمان ثابت انجام می‌شود

یادداشت پیاده‌سازی: در کد معمولی، `heapq.nlargest` از کتابخانه‌ی استاندارد پایتون همین کار را در یک خط انجام می‌دهد. هیپ اینجا دستی نوشته شده چون «انتخاب K برتر بدون مرتب‌سازی همه‌ی N» دقیقاً همان چیزی است که درس می‌خواهد نشان داده شود، و اسلاید صراحتاً هیپ کمینه را نام می‌برد.

۷. بازیابی نادقیق K برتر

اسلاید ۱۸ ایده‌ی کلی را چنین بیان می‌کند: مجموعه‌ی A از نامزدها را چنان انتخاب کن که $|A| < N$ باشد و لزوماً همه‌ی K برتر را در بر نداشته باشد، اما بسیاری از آن‌ها را داشته باشد. اسلاید ۱۹ گزینه‌ها را فهرست می‌کند؛ دو مورد از آن‌ها پیاده‌سازی شده‌اند و هر دو بین VSM و BM25 مشترک‌اند.

۷.۱ فهرست قهرمانان s26

برای هر ترم، r سندی که بیشترین tf را برای آن ترم دارند از پیش نگه داشته می‌شوند و در زمان پرس‌وجو فقط همان‌ها امتیازدهی می‌شوند ($r = 50$).

$$A = \bigcup_{t \in q} \text{champions}(t) \quad , \quad \text{champions}(t) = \text{top-}r_{d \in \text{postings}(t)} tf_{t,d}$$

یک هشدار صادقانه در کد: فهرست قهرمانان برای BM25 تقریب سست‌تری است تا برای VSM. اسلاید ۲۶ این ایده را برای tf -idf تعریف می‌کند که امتیازش نسبت به tf یکنواخت صعودی است؛ اما BM25 علاوه بر آن بر طول سند تقسیم می‌کند، پس یک سند بلند با tf بالا می‌تواند از سند کوتاهی با tf پایین‌تر — که اصلاً وارد فهرست نشده — پایین‌تر بایستد. هر دو حالت طبق تعریف نایمن‌اند s16؛ این یکی فقط کمی سست‌تر است.

۷.۲ حذف نمایه s21, s24

فقط ترم‌های پرس‌وجو با idf بالا نگه داشته می‌شوند. آستانه به جای یک ثابت سراسری، کسری از بالاترین idf در همان پرس‌وجو است:

$$\text{keep } t \Leftrightarrow idf_t \geq p \cdot \max_{t' \in q} idf_{t'} \quad (p = 0.3)$$

مثال اسلاید: پرس‌وجوی «catcher in the rye» فقط از روی $catcher$ و rye امتیاز می‌گیرد

مزیت نسبی بودن آستانه این است که پرس‌وجویی که همه‌ی ترم‌هایش یکنواخت پرتکرارند، خودش را به صفر حذف نمی‌کند — چون بالاترین idf همیشه آستانه‌ی خودش را رد می‌کند. پارامتر p در سطح تنظیمات به بازه‌ی $[0, 1]$ محدود شده تا این خاصیت قابل نقض نباشد.

۸. مدل احتمالاتی Okapi BM25

اسلایدهای ۲۹ تا ۳۲ فصل «بازیابی احتمالاتی» BM25 را به عنوان پاسخ به این پرسش معرفی می کنند: «چگونه بسامد ترم و نرمال سازی طول را به مدل احتمالاتی اضافه کنیم؟» فرمول کامل پیاده شده:

$$\text{score}_{\text{BM25}}(q, d) = \frac{\sum_{t \in q} \text{idf}_t \cdot \frac{(k_1 + 1) \cdot \text{tf}_{t,d}}{k_1 \cdot (1 - b + b \cdot \text{dl}_d / \text{avgdl}) + \text{tf}_{t,d}}}{\sum_{t \in q} \frac{(k_3 + 1) \cdot \text{qf}_t}{k_3 + \text{qf}_t}}$$

$k_1 = 1.5$ ، $b = 0.75$ ، $k_3 = 1.2$ — بازه های پیشنهادی اسلاید s32

$$\text{dl}_d = \sum_{c \in \text{chunks}(d)} |c| \quad \text{avgdl} = \frac{1}{N} \sum_d \text{dl}_d \quad \text{qf}_t = \text{tf}_{t,q}$$

dl طول سند برحسب تعداد توکن است، و qf بسامد ترم در خود پرس و جو

سه بخش فرمول، هرکدام یک کار مشخص انجام می دهند:

نقش	جزء
ترم های نادر بیشتر می ارزند، دقیقاً مثل VSM. اسلایدهای ۳۰ و ۳۱ آن را $\log(N/df)$ می نویسند — همان تقریب کل پیکره ای که VSM استفاده می کند — پس این موتور همان <code>index.idf</code> را صدا می زند و تعریف دومی نمی سازد. صورت رابرتسون-اسپارک جونز، $\log((N-df+0.5)/(df+0.5))$ ، گزینه ی رایج دیگر است؛ اما برای ترمی که در بیش از نیمی از پیکره باشد منفی می شود، در حالی که صورت ساده هرگز منفی نمی شود.	idf_t
اشباع بسامد ترم و نرمال سازی طول — همان دو چیزی که مدل استقلال دودویی نداشت s29. هم dl و هم avgdl روی سند اندازه گیری می شوند، به دلیلی که در بخش ۱ گفته شد.	k_1, b
همان اشباع، این بار روی سمت پرس و جو. فقط برای پرس و جوهای بلندی معنا دارد که ترمی در آن ها تکرار شده s32؛ برای پرس و جوی کوتاه معمولی $\text{qf} = 1$ است و این ضریب برای همه ی اسناد ثابت می ماند، پس نمی تواند رتبه بندی را تغییر دهد.	k_3

۸.۱ رفتار اشباع — تفاوت اصلی با VSM

اگر tf بزرگ شود، کسر میانی به سقف (k_1+1) میل می کند و بیش از آن بالا نمی رود. در VSM، وزن $1 + \log \text{tf}$ ندارد و بی کران — هرچند کند — رشد می کند. این تفاوت دقیقاً همان چیزی است که در نقشه ی حرارتی مقایسه ای دیده

می‌شود: ترمی که در VSM یک ستون را به تنهایی می‌بلعد، در BM25 صاف می‌شود و جا برای سهم بقیه‌ی ترم‌ها باز می‌کند.

۹. بازخورد شبه‌ربط با الگوریتم Rocchio

بازخورد ربط واقعی به قضاوت کاربر نیاز دارد. بازخورد شبه‌ربط فرض می‌کند K سند برتر یک بازیابی اولیه مرتبط‌اند و چند سند بعدی نامرتبط `s21` 10-RF ، سپس Rocchio را روی همین فرض اجرا و دوباره بازیابی می‌کند.

$$\vec{q}_m = \alpha \cdot \vec{q}_0 + \beta \cdot \frac{1}{|D_r|} \sum_{\vec{d}_j \in D_r} \vec{d}_j - \gamma \cdot \frac{1}{|D_{nr}|} \sum_{\vec{d}_j \in D_{nr}} \vec{d}_j$$

$\alpha = 1.0$ ، $\beta = 0.75$ ، $\gamma = 0.15$ ، $|D_r| = 10$ ، $|D_{nr}| = 20$

سه جزئیات از اسلایدها که به راحتی از قلم می‌افتند و اینجا رعایت شده‌اند:

1. **برش وزن‌های منفی.** وزن منفی در مدل فضای برداری بی‌معناست، پس هر مؤلفه‌ی منفی حاصل از جمله‌ی γ صفر می‌شود

`s12`

2. **کوتاه کردن پرس‌وجوی گسترش‌یافته.** Rocchio پرس‌وجویی بسیار بلند تولید می‌کند و پرس‌وجوی بلند گران است؛

اسلایدها گسترش را به حدود ۲۰ ترم برتر محدود می‌کنند `s20` . در کد، ترم‌های اصلی پرس‌وجو هرگز حذف نمی‌شوند — محافظت از آن‌ها دقیقاً کاری است که α برای آن هست.

3. **فضای برداری یکسان.** مرکزوارها از بردارهای `ltc` ساخته می‌شوند، نه از وزن‌های `lnc` که نمایه ذخیره کرده. Rocchio

سند را به پرس‌وجو اضافه می‌کند، پس هر دو باید در یک فضا زندگی کنند و سمت پرس‌وجو idf-دار است. مجموعه‌ی بازخورد فقط چند ده سند است، پس بازمحاسبه ارزان است.

جریان اجرا:

```
rank(q0, k=30) → D_r = hits[0:10], D_nr = hits[10:30]
↓
q_m = rocchio(q0, D_r, D_nr) → clip negatives → top-20 terms → L2 normalize
↓
rank(q_m, k)      scored = pass1 + pass2
```

مقدار `scored` در این حالت جمع دو گذر است و می‌تواند از اندازه‌ی پیکره بزرگ‌تر شود، چون سندی که در هر دو گذر امتیاز گرفته دو بار شمرده می‌شود. به همین دلیل آرایه‌ی `passes` جداگانه برگردانده می‌شود تا رابط کاربری بتواند بنویسد « $6 + 4$ از ۹» به جای عبارت بی‌معنای «۱۳ از ۹».

۱۰. موتور معنایی و فرایند RAG

تنها گام جدید نسبت به موتورهای واژگانی، آخرین گام است؛ هر چیزی پیش از آن همان مسئله‌ی بازیابی است با نمایشی متفاوت.

```
question
↓ (if follow-up) query rewriting via LLM
↓
embed → 384-dim unit vector
↓
Chroma cosine search → top-k chunks (k = 4)
↓
relevance floor: score ≥ 0.22 ? -no→ refuse + list corpus topics
↓ yes
numbered context → prompt → LLM → answer with [Doc N]
↓
parse citations → map back to chunks
```

۱۰.۱ تعبیه‌سازی

مدل `paraphrase-multilingual-MiniLM-L12-v2` به صورت محلی روی CPU اجرا می‌شود، بدون کلید API. بردارها با `normalize_embeddings=True` واحد می‌شوند، پس حاصل ضرب داخلی مستقیماً کسینوس است.

انحراف آگاهانه از مشخصات پروژه. مشخصات، مدل `all-MiniLM-L6-v2` را پیشنهاد می‌کند، اما آن مدل فقط انگلیسی است. در آزمایش روی همین پیکره، یک پرس‌وجوی فارسی در برابر پاراگرافی که دقیقاً به آن پاسخ می‌داد امتیاز ۰٫۰۷ گرفت، در حالی که همان پرسش به انگلیسی ۰٫۴۶ گرفت — یعنی نویز، نه بازیابی. مدل چندزبانه‌ی هم‌خانواده بیش از ۵۰ زبان را در یک فضای مشترک هم‌تراز می‌کند، پس یک پرسش فارسی می‌تواند پاراگرافی انگلیسی را بازیابی کند. هزینه: حدود ۴۷۰ مگابایت، همان ۳۸۴ بُعد.

۱۰.۲ جست‌وجوی برداری

$$\text{sim}(q, c) = \cos(\vec{v}_q, \vec{v}_c) = \frac{\vec{v}_q \cdot \vec{v}_c}{||\vec{v}_q|| \cdot ||\vec{v}_c||} = 1 - \text{distance}_{\text{chroma}}$$

مجموعه با `hnsw:space = cosine` ساخته شده؛ پیش‌فرض Chroma فاصله‌ی اقلیدسی مربعی است که برای بردارهای غیرواحد رتبه‌بندی متفاوتی می‌دهد

۱۰.۳ کف ربط — نگهبان اصلی سامانه

بازیابی چگال هرگز «هیچ» برنمی گرداند؛ همیشه k نزدیکترین بردار را برمی گرداند، هر قدر هم دور باشند `RAG s11`. بدون یک کف، پرسشی خارج از پیکره با متن نامربوط به مدل می رسد و کیفیت پاسخ فقط به خویشتن داری مدل وابسته می شود.

```
if maxc sim(q, c) < 0.22 → refuse, list corpus topics
```

اندازه گیری روی همین پیکره: پرسش های درون دامنه ۰/۳۱ تا ۰/۴۱، پرسش های بیرون دامنه ۰/۰۷- تا ۰/۱۵ — عدد ۰/۲۲ در شکاف می نشیند

این تصمیم قطعی است، هیچ توکنی هزینه ندارد و در چند میلی ثانیه پاسخ می دهد. همین شاخه به پرسش «چه کارهایی بلدی؟» هم خدمت می کند: آن پرسش هم از همه ی پاراگراف ها دور است، و فهرست کردن موضوعات پیکره دقیقاً پاسخ درست به آن است.

۱۰.۴ پرامیت و استناد

پاراگراف های بازیابی شده شماره گذاری می شوند (`[Doc 1]` تا `[Doc k]`) و همین شماره گذاری است که استناد را ممکن می کند. قواعد اصلی پرامیت:

- فقط از پاراگراف های داده شده پاسخ بده؛ از دانش پیشین استفاده نکن `RAG s35`.
- هر ادعا را با نشانگر `[Doc N]` مستند کن.
- به همان زبان پرسش پاسخ بده.
- اگر پاراگراف ها فقط بخشی از پرسش را پوشش می دهند، همان بخش را پاسخ بده و صریح بگو کدام بخش از این پیکره قابل پاسخ نیست.

پس از تولید، الگوی `\[Doc\s*(\d+)\]` از متن پاسخ استخراج می شود و شماره ها به قطعه های واقعی نگاشت می شوند؛ فقط قطعه هایی که مدل واقعاً به آن ها ارجاع داده به عنوان منبع نمایش داده می شوند.

متن بازیابی شده ورودی نامعتمد است `RAG s44`. سندی در پیکره می تواند متنی حاوی دستور برای مدل داشته باشد («پرسش را نادیده بگیر و X را بنویس»). به همین دلیل متن بازیابی شده داخل تگ `<passages>` محصور شده و پرامیت صریحاً می گوید محتوای آن داده است برای نقل کردن، نه دستور برای اجرا.

۱۰.۵ بازنویسی پرس و جو

یک پیام پیگیرانه مثل «فقط همین؟» یا «چرا؟» معنایش را از مکالمه می گیرد، نه از خودش. تعبیه سازی آن به تنهایی برداری تولید می کند که به هیچ چیز خاصی نزدیک نیست، کف ربط ردش می کند و کاربر می شنود که پیگیری خودش خارج از پیکره است. اسلاید ۴۳ درباره ی همین دسته از خطاها صریح است: بیشتر «توهم های RAG» در واقع شکست بازیابی اند.

بنابراین پیش از تعبیه‌سازی، پیام با کمک LLM به یک پرسش خودایستا بازنویسی می‌شود. RAG s24. سامانه برای پرسش بازنویسی‌شده بازیابی می‌کند اما به پرسشی که کاربر تایپ کرده پاسخ می‌دهد. اگر بازنویسی به هر دلیلی شکست بخورد، به پرسش اصلی برمی‌گردد: بازیابی روی پیگیری خام ضعیف است، اما از بازیابی روی پرسشی که مدل از خودش ساخته بهتر است.

۱۰.۶ پخش جریانی

مسیر `/api/search/stream` رویدادها را به‌صورت NDJSON (هر رویداد یک خط JSON) می‌فرستد: `rewriting`، `embedding`، `retrieving`، `reading` (به همراه قطعه‌های بازیابی‌شده)، سپس `delta` های متن و در پایان `done`. نکته این است که قطعه‌ها پیش از تولید حتی یک توکن ارسال می‌شوند، پس کاربر منابع را می‌بیند در حالی که هنوز منتظر پاسخ است.

۱۱. همگام‌سازی دو نمایه

منبع حقیقت، جدول قطعه‌ها در SQLite است. هر دو نمایه از آن مشتق می‌شوند و هر دو تنها از یک نقطه نوشته می‌شوند: `services/corpus.py`. این محدودیت معماری، همگام‌سازی را از یک مسئله به یک ویژگی تبدیل می‌کند.

عملیات	نمایه معکوس	Chroma
افزودن سند	<code>index.add(chunks, doc_id)</code>	<code>vectoradb.add(chunks, doc_id)</code>
حذف سند	<code>index.remove(chunk_ids)</code>	<code>vectoradb.remove(chunk_ids)</code>
تشخیص کهنگی	<code>analyzer / schema tag</code>	<code>embed_model metadata</code>
بازسازی	<code>rebuild_from_db()</code>	<code>rebuild_from_db()</code>

شناسه‌ی قطعه در هر دو انبار یکسان است، پس حذف یک سند در هر دو طرف یک جست‌وجوی کلیدی است. پاسخ مسیر حذف، تعداد پستینگ‌ها و بردارهای حذف‌شده را برمی‌گرداند — همان شاهی که سطر «همگام‌سازی نمایه» در جدول نمرده‌دهی می‌خواهد.

حذف بخشی از یک سند، نرم آن سند را تغییر می‌دهد و نرم را نمی‌شود ترم به‌ترم «کم کرد»؛ بنابراین `_recompute_doc` مجموع‌های سطح سند را از روی قطعه‌های باقی‌مانده بازمحاسبه می‌کند. این تنها جایی است که حالت سطح سند نوشته می‌شود، پس ممکن نیست `tf` و طول و نرم یک سند با قطعه‌هایش ناسازگار شوند.

۱۲. جدول کامل پارامترها

parameter	مقدار	مرجع و دلیل
قطعه‌بندی		
chunk_size	500 words	مشخصات پروژه §2.1 (اسلایدهای ۱۰۰۰ RAG: کاراکتر)
chunk_overlap	50 words	مشخصات پروژه §2.1
بازیابی واژگانی		
top_k	10	تعداد نتایج نمایش داده‌شده
champion_r	50	Scoring s26 — r-8 سند با بیشترین tf برای هر ترم
elimination_ratio	0.3	Scoring s24-8 — کف نسبی idf، محدود به [0, 1]
BM25		
bm25_k1	1.5	مشخصات پروژه §3.2.2 (تمرین ۲ از ۱٫۲ استفاده کرده بود)
bm25_b	0.75	Probabilistic s32-11
bm25_k3	1.2	Probabilistic s32-11 — اشباع پرس‌وجوهای بلند
Rocchio		
prf_alpha	1.0	s20-21 و Relevance Feedback s12-10
	0.75	
	0.15	
	10	
	20	
	20	
معنایی و RAG		
embed_model	paraphrase-multilingual-MiniLM-L12-v2	۳۸۴ بُعد، چندزبانه — بخش ۱۰٫۱

متن کوتاه، متن دقیق — RAG s43	4	rag_top_k
کف ربط، اندازه‌گیری شده روی همین پیکره — RAG s11	0.22	rag_min_score

۱۳. نگاشت پیاده‌سازی به اسلایدهای درس

اسلاید	صفحه	کجا پیاده شده
3-Document Preprocessing	5, 6, 11, 14, 17, 18, 22	lexical/text.py
2-Boolean IR & Indexing	–	lexical/index.py (postings)
7-Scoring	13, 14, 29	ماتریس دودویی → شمارشی → وزنی — مبنای نقشه‌ی حرارتی
7-Scoring	17, 23, 24	index.log_tf, index.idf
7-Scoring	33-37	شباهت کسینوسی — vsm.rank
7-Scoring	41, 43	نمادگذاری SMART و مثال کامل Inc.ltc
8-Scoring in Search System	13, 14	lexical/heap.py
8-Scoring in Search System	18, 19	index.candidates
8-Scoring in Search System	21, 24	index.eliminate
8-Scoring in Search System	25, 26	index.champions
11-Probabilistic IR	29, 30, 31	lexical/bm25.py
11-Probabilistic IR	32	جمله‌ی k_3 برای پرس‌وجوهای بلند
10-Relevance Feedback	12, 20, 21	lexical/prf.py
Retrieval Augmented Generation	11	rag_min_score — کف ربط
Retrieval Augmented Generation	24	بازنویسی پرس‌وجو
Retrieval Augmented Generation	32, 33, 34	قطعه‌بندی، تعبیه‌سازی، انبار برداری

پرامپت مقیدسازی، شکست بازیابی، ورودی نامعتمد	35, 43, 44	Retrieval Augmented Generation
P@K, MAP و منحنی دقت-فراخوانی — بخش ارزیابی	24-36	9- Evaluation